

KOMAAI

PLATAFORMA DE DELIVERY

Infraestrutura, Capacidade e Custos

Relatório técnico-financeiro para apresentação a investidores: estrutura de custos atual, capacidade de operação estimada e cenários de crescimento.

Preparado para

Investidores / Board — KomaAI

Data

Setembro de 2026

Autor

Bruno Belloti

Confidencialidade

Uso interno / não distribuir

1. Resumo executivo

A KomaAI opera hoje sobre uma infraestrutura enxuta, adequada para a fase de validação em que o produto se encontra: 1 servidor de aplicação e 1 banco de dados gerenciado na AWS, totalizando **US\$ 39,00/mês** de infraestrutura de nuvem, mais os custos das lojas de aplicativo (Apple e Google).

Esta infraestrutura é suficiente para operar um piloto real — dezenas de restaurantes, milhares de produtos e algumas dezenas de pedidos simultâneos — mas possui gargalos técnicos claros e conhecidos (detalhados na Seção 5) que devem ser endereçados antes de uma expansão para múltiplas cidades ou picos de demanda relevantes (ex: lançamento com campanha de marketing).

US\$ 39	~20	~5	~10 mil
custo de infra/mês hoje	checkouts simultâneos	conversas de IA simultâneas	produtos suportados

Principal conclusão para investidores: o custo de infraestrutura é hoje irrelevante frente a qualquer métrica de negócio (39 USD/mês), e mesmo o próximo degrau de investimento em infraestrutura para suportar centenas de pedidos/dia simultâneos custa menos de US\$ 100/mês (Seção 6). O gargalo da fase atual não é financeiro — é de arquitetura (um único processo atendendo tudo, incluindo os módulos de inteligência artificial), e tem correções de baixo custo já mapeadas.

2. Infraestrutura atual e custos

A tabela abaixo resume os componentes de infraestrutura em operação, com as especificações informadas pela equipe técnica e confirmadas diretamente no servidor de produção.

Componente	Especificação	Custo
Servidor de aplicação (AWS EC2)	2 vCPUs · 4 GB RAM · 80 GB SSD (instância t3.medium, confirmada)	US\$ 24,00
Banco de dados (AWS RDS MySQL)	~1 GB RAM · 40 GB SSD	US\$ 15,00
Armazenamento de imagens (AWS S3)	Fora do servidor/banco — escala à parte, custo variável por volume (não medido neste relatório)	variável*
IA conversacional (Google Gemini API)	Custo por uso (tokens), fora da infra fixa	variável*
Processamento de pagamentos (Stripe)	Taxa por transação, fora da infra fixa	variável*

**Custos variáveis dependem de volume de uso e não foram medidos/faturados ainda em escala — recomenda-se acompanhá-los à parte assim que houver tráfego real de usuários.*

2.1 Lojas de aplicativo

Item	Descrição	Custo
Apple Developer Program	Obrigatório para publicar/manter o app na App Store	US\$ 99,00/ano (≈ US\$ 8,25/mês)

Item	Descrição	Custo
Google Play Console	Taxa única de registro de conta de desenvolvedor	US\$ 25,00 (pagamento único)

RESUMO DE CUSTO — Custo total recorrente atual ≈ **US\$ 47,25/mês** (US\$ 39,00 de infraestrutura de nuvem + US\$ 8,25 de conta Apple), mais **US\$ 25,00 pagos uma única vez** para a conta Google Play. Custos variáveis de S3, Gemini e Stripe somam-se a isso proporcionalmente ao volume de uso.

3. Como os números de capacidade foram estimados

As estimativas de capacidade apresentadas nas Seções 4 e 6 são **estimativas de engenharia**, baseadas em três fontes concretas:

- Especificações reais de hardware confirmadas no servidor em produção (CPU, memória, tipo de instância, uso de memória do processo em tempo real);
- Configuração real da aplicação (número de processos do servidor web, tamanho do pool de conexões com o banco de dados, limite de conexões do MySQL);
- Telemetria observada nos registros (*logs*) de produção — por exemplo, tempo de resposta do modelo de busca por IA e das chamadas à API de IA conversacional (Gemini) em uso real.

LIMITAÇÃO METODOLÓGICA — Estes números **não substituem um teste de carga formal** (ferramentas como k6, Locust ou JMeter, simulando usuários reais concorrentes). Recomendamos fortemente executar esse tipo de teste antes de assumir compromissos contratuais, operacionais ou financeiros com terceiros com base nestas estimativas. Este relatório deve ser lido como um retrato de capacidade planejada, não como um SLA medido.

3.1 O que descobrimos ao inspecionar o servidor em produção

Aspecto	O que foi observado
Processos do servidor web	1 único processo ("worker") atende todas as requisições HTTP
Memória em uso	2,5 GB de 3,7 GB disponíveis (68%) já ocupados de forma fixa, majoritariamente pelo modelo de IA de busca semântica (<i>multilingual-e5-large</i>) carregado permanentemente em memória
Conexões ao banco	Pool de 5 conexões fixas + 10 extras (15 no total) por parte da aplicação; o MySQL aceita até 61 conexões simultâneas no total
Armazenamento de imagens	Fica no Amazon S3, fora do disco do servidor e do banco — ou seja, o catálogo de produtos não é limitado pelos 80 GB / 40 GB de disco citados
Volume de dados hoje	5 restaurantes, 22 produtos, 4 pedidos, 4 estafetas cadastrados — ambiente de validação/pré-lançamento

4. Capacidade estimada — infraestrutura atual

Com base na metodologia da Seção 3, a infraestrutura atual (US\$ 39/mês) suporta, de forma confortável e sem degradação perceptível de performance, os seguintes volumes:

Recurso	Fator limitante	Estimativa
Restaurantes cadastrados	Sem limite técnico direto — cada restaurante consome apenas linhas leves de banco de dados	Centenas a milhares
Produtos/pratos cadastrados	Limitado pelo índice de busca por IA mantido em memória (~4 KB por produto). Imagens não contam aqui, pois ficam no S3.	5.000 – 10.000 produtos
Checkouts/pedidos simultâneos (sem uso de IA)	Operação leve de banco de dados; limitada pelo pool de 15 conexões e pelo processo único do servidor	15 – 25 simultâneos
Conversas simultâneas com o assistente de IA (chat de vendas)	Maior gargalo: cada conversa consome CPU local (busca semântica) e depende da resposta do Gemini (observado entre 5 e 25 segundos por interação nos logs reais)	3 – 8 simultâneas
Estafetas (drivers) usando o app simultaneamente	Operação leve — apenas consulta de pedidos disponíveis e atualização de localização	30 – 50 simultâneos

Leitura para investidores: a plataforma já suporta, na infraestrutura atual, um piloto real em uma cidade de porte médio (dezenas de restaurantes ativos, algumas dezenas de pedidos por hora). O ponto de atenção é o **assistente de IA**: por rodar no mesmo processo que atende pedidos comuns, um pico de uso do chat pode atrasar checkouts de outros usuários ao mesmo tempo. Esse é o primeiro investimento técnico recomendado antes de qualquer campanha de marketing de maior porte (ver Seção 6).

5. Riscos técnicos identificados

Risco	Descrição
Ponto único de falha	Toda a aplicação roda em uma única instância EC2. Qualquer falha de hardware, SO ou pico de uso derruba a plataforma inteira até um reinício manual/automático.
Processo único do servidor web	Uma operação lenta (ex: chamada de IA) pode atrasar todas as demais requisições em andamento naquele instante, mesmo pedidos simples de checkout.
Banco de dados sem redundância (Multi-AZ)	Não identificamos configuração de alta disponibilidade no banco — uma falha do RDS interrompe a plataforma até restauração manual.
Ausência de testes de carga formais	As estimativas desta Seção 4 nunca foram validadas com uma ferramenta de teste de carga real; o comportamento sob pico real pode diferir do estimado.

Nenhum destes riscos é incomum para a fase de um produto em validação — são, na prática, o roteiro natural de investimento técnico à medida que a tração cresce.

6. Cenários de crescimento e investimento em infraestrutura

A tabela e os cartões abaixo projetam três horizontes de investimento em infraestrutura, do ajuste mais barato (configuração, sem custo adicional de nuvem) até uma operação multi-cidade.

CENÁRIO 0 — Atual (piloto)

US\$ 39/mês

infraestrutura de nuvem

- t3.medium + RDS 1 GB RAM
- ~10 mil produtos, ~20 checkouts simultâneos
- ~5 conversas de IA simultâneas

CENÁRIO 1 — Ajuste de configuração

US\$ 39–70/mês

mesma infra ou upgrade parcial

- Múltiplos processos + IA desacoplada do fluxo de checkout
- Ganho de 2×–3× em checkouts simultâneos
- Requer mais RAM se rodar 2+ cópias do modelo de IA

CENÁRIO 2 — Crescimento inicial

US\$ 90–100/mês

centenas de pedidos/dia

- EC2 t3.large (8 GB RAM) + RDS db.t3.small
- 50–80 checkouts simultâneos
- 15–20 conversas de IA simultâneas · ~150 drivers

CENÁRIO 3 — Escala multi-cidade

US\$ 250–450/mês

milhares de pedidos/dia

- 2–3 servidores com balanceamento de carga + banco maior
- IA processada em fila separada (não trava checkout)
- Centenas de checkouts simultâneos · 500+ drivers

Os valores de custo de infraestrutura dos Cenários 2 e 3 são estimativas de mercado para instâncias AWS equivalentes (sob demanda, sem desconto de reserva) e não consideram descontos por compromisso de longo prazo (Reserved Instances ou Savings Plans), que tipicamente reduzem esses valores entre 30% e 50% quando o volume de uso se torna previsível.

7. Custo de infraestrutura por pedido (referência)

Para dar uma noção de ordem de grandeza do custo de infraestrutura por pedido processado — métrica relevante em conversas de unit economics — a tabela abaixo projeta o custo de infraestrutura fixo mensal dividido por diferentes volumes mensais de pedidos hipotéticos, mantendo o Cenário 0 (US\$ 39/mês) como base.

Volume mensal de pedidos	Custo de infra por pedido
500 pedidos/mês (~17/dia)	US\$ 0,078 / pedido
2.000 pedidos/mês (~65/dia)	US\$ 0,020 / pedido
5.000 pedidos/mês (~165/dia)	US\$ 0,008 / pedido
15.000 pedidos/mês (~500/dia)	US\$ 0,003 / pedido

Não inclui custos variáveis de IA (Gemini), armazenamento de imagens (S3) e processamento de pagamentos (Stripe), que escalam proporcionalmente ao volume e devem ser medidos separadamente assim que houver faturamento real.

LEITURA PARA INVESTIDORES — Mesmo em um cenário de 500 pedidos/mês (bem abaixo da capacidade real do Cenário 0), o custo de infraestrutura por pedido já é inferior a 8 centavos de dólar. Isso reforça que a infraestrutura de nuvem não é, hoje, um fator relevante de custo unitário do negócio — o investimento técnico recomendado (Seção 6) é sobre resiliência e experiência do usuário, não sobre redução de custo.

8. Recomendações

- **Validar com teste de carga real** antes de qualquer campanha de marketing de maior porte ou compromisso contratual com restaurantes/parceiros baseado nos números da Seção 4.
- **Desacoplar o assistente de IA do fluxo de checkout** — é o ajuste de menor custo e maior impacto na capacidade atual (Cenário 1).
- **Definir gatilhos de upgrade por métrica** (ex: uso de CPU acima de 70% sustentado, ou tempo de resposta acima de X segundos), em vez de datas fixas de calendário, para investir em infraestrutura no momento certo.
- **Ativar redundância básica** (Multi-AZ no banco de dados, ao menos) antes do lançamento público, dado o baixo custo incremental frente ao risco de indisponibilidade total.

Relatório preparado por Bruno Belloti, equipe de engenharia da KomaAI, a partir de inspeção direta do ambiente de produção em setembro de 2026. Os valores de custo de infraestrutura em nuvem (Cenários 1–3) são estimativas de mercado sujeitas a alteração pelos provedores de nuvem; os valores do Cenário 0 refletem o faturamento real informado pela equipe.